

Aula 2b

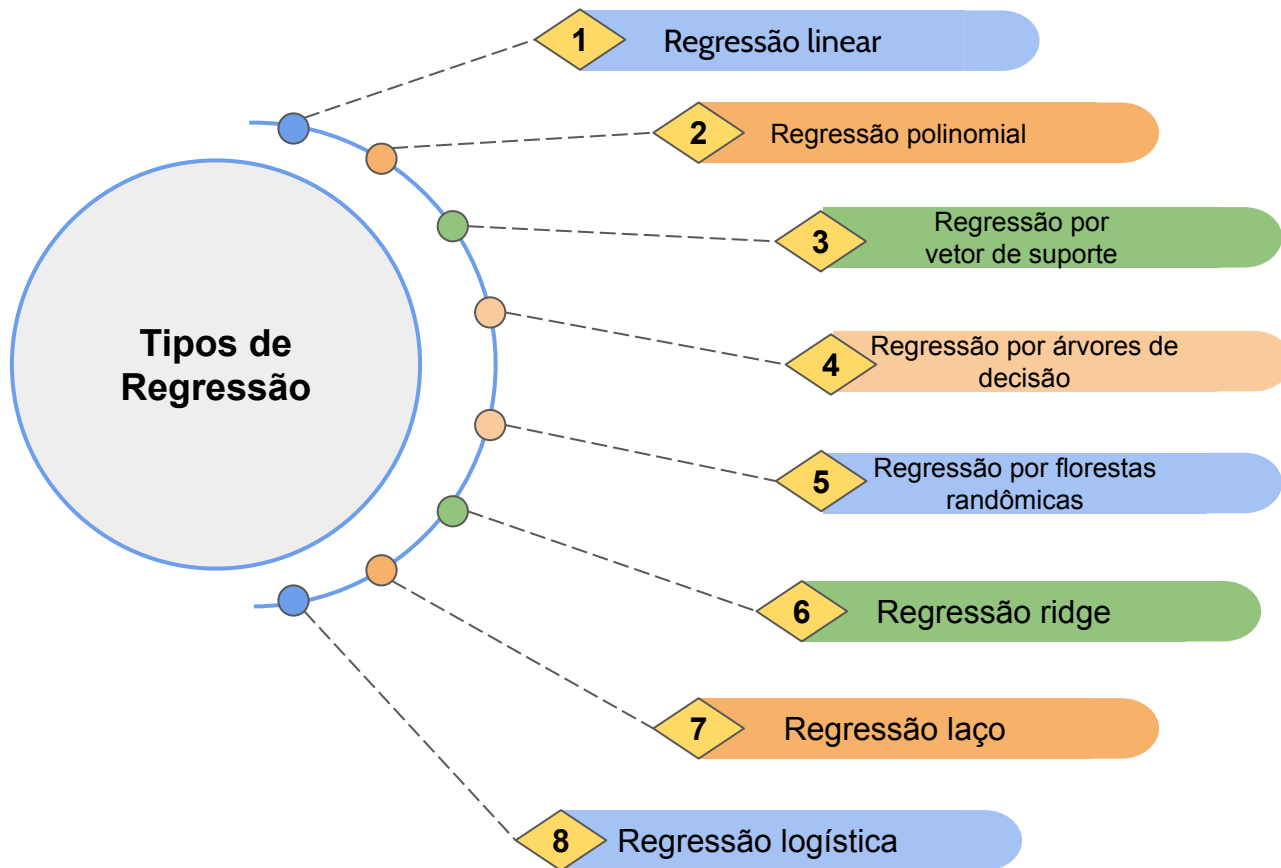
Regressão Linear

Adaptado dos slides do Prof Samuel Botter

O que é uma regressão?


- É uma abordagem para modelar o relacionamento entre variáveis numéricas independentes (explicativas) e dependentes, ajustando um modelo (uma curva qualquer) para as observações de um conjunto de treinamento.
- Este modelo pode então ser usado para prever aquelas variáveis numéricas dependentes para novas observações ainda não observadas das variáveis explicativas
- Quando esta curva é uma reta, diz-se que a regressão é **linear**

Tipos de regressão




Regressão Linear X Logística

Regressão Linear



Regressão Logística



Variáveis dependentes e independentes

“causas”
variáveis independentes

“efeito”
variável independente

Idade	Titulação	Experiência	Salário Anual
21	Graduação	1	35.000,00
25	Especialização	5	80.000,00
35	Doutorado	10	120.000,00
...

Conjunto de Treinamento

Uma variável independente

$$\hat{y} = b_0 + b_1 \cdot x$$

Modelo Linear


variáveis independentes

variável dependente

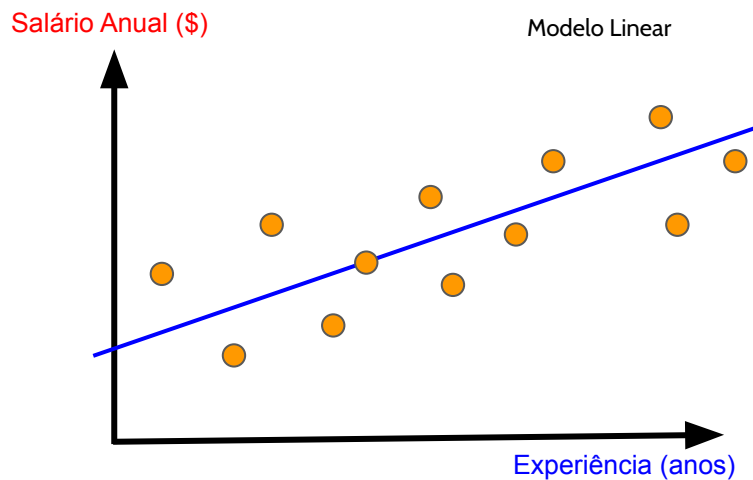
Experiência	Salário Anual
1	35.000,00
5	80.000,00
10	120.000,00
...	...

Conjunto de Treinamento

Salário Anual (\$)



Regressão Linear Simples



$$\underbrace{h(x_1)}_{\text{hipótese}} = \underbrace{\hat{y}}_{\substack{\text{variável} \\ \text{dependente}}} = \underbrace{\hat{b}_0}_{\text{intercepto}} + \underbrace{b_1}_{\text{inclinação}} \cdot \underbrace{x}_{\substack{\text{variável} \\ \text{independente}}}$$

$$\text{salário} = b_0 + b_1 \cdot \text{experiência}$$

Equação da Reta

$$(y - y_0) = \mu \cdot (x - x_0)$$

simplificando para $x_0 = 0$


$$(y - y_0) = \mu \cdot x$$

$$y = \underbrace{y_0}_{\text{intercepto}} + \underbrace{\mu}_{\text{inclinação}} \cdot x$$

$$h(x) = \hat{y} = \underbrace{b_0}_{\text{intercepto}} + \underbrace{b_1}_{\text{inclinação}} \cdot x$$


$$\mu = b_1 = \tan(\theta)$$

$$\theta = \arctan(\mu)$$




Equação da Reta : exemplos


$$h(x) = \hat{y} = \overbrace{b_0}^{\text{intercepto}} + \underbrace{b_1}_{\text{inclinação}} \cdot x$$



$$b_0 = 2.0$$
$$b_1 = 0.0$$

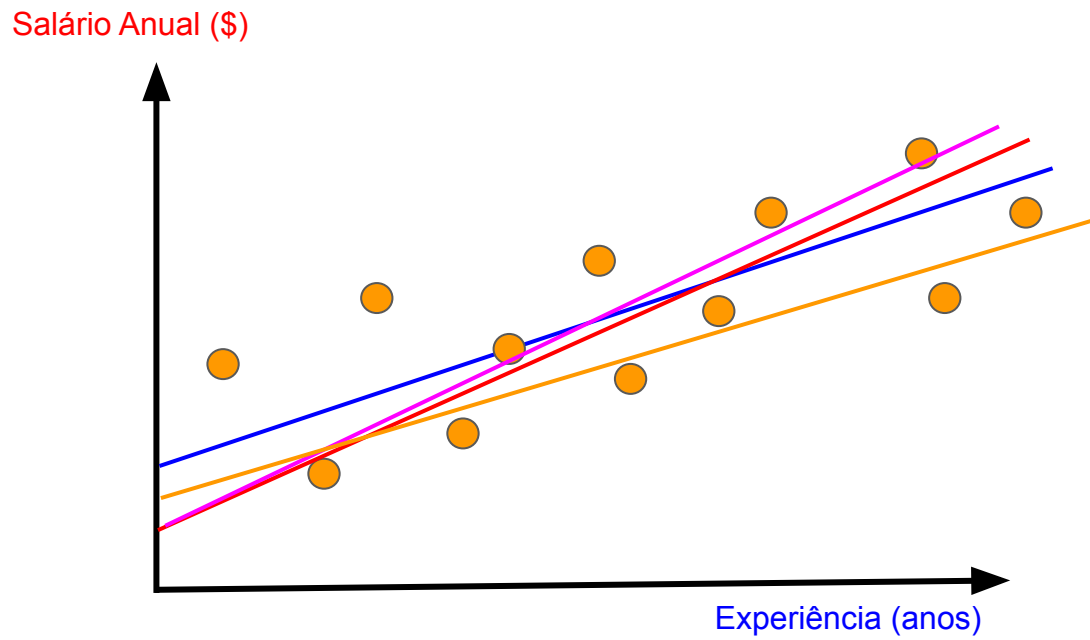


$$b_0 = 0.0$$
$$b_1 = 1.0$$
$$(\theta = 45^\circ)$$




$$b_0 = 1.0$$
$$b_1 = 0.5$$
$$(\theta \approx 27^\circ)$$

Qual a melhor reta ?



Erro do modelo linear

Objetivo: achar os parâmetros b_0 e b_1 que minimizam a função de custo para o conjunto de treinamento



$$MSE = f_c(b_0, b_1) = \frac{\sum_{i=1}^N (\hat{y} - y_i)^2}{N}$$

(Mean Squared Error)

A reta de menor valor da função de custo

Modelo linear (hipótese)

$$h(x) = \hat{y} = b_0 + b_1 \cdot x$$

Modelo linear Simplificado

$$h(x) = \hat{y} = b_1 \cdot x$$

simplificando $b_0 = 0$

Função de Custo

$$fc(b_0, b_1) = MSE = \frac{\sum_{i=1}^N (\hat{y} - y_i)^2}{N}$$

Função de Custo

$$fc(b_1) = MSE = \frac{\sum_{i=1}^N (\hat{y} - y_i)^2}{N}$$

Objetivo

$$\min_{b_0, b_1} (fc(b_0, b_1))$$


Objetivo

$$\min_{b_1} (fc(b_1))$$

Exemplo de função de custo

$$h(x) = \hat{y} = b_1 \cdot x$$

$$b_1 = 1$$

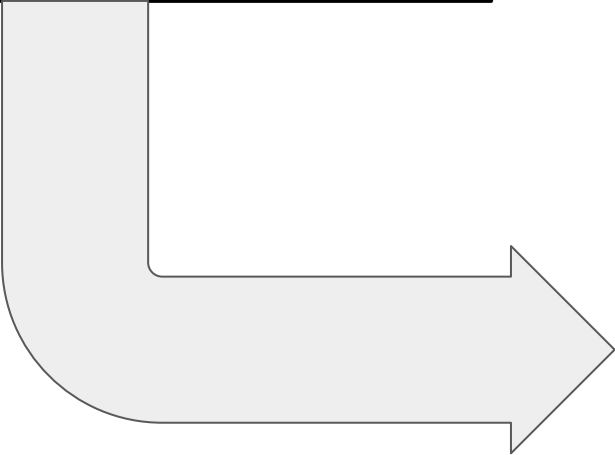


$$fc(b_1) = MSE = \frac{\sum_{i=1}^N \left(\overbrace{b_1 \cdot x_i}^{\hat{y}} - y_i \right)^2}{N}$$



Resumo da ideia de minimização

É um processo de otimização.
A função de custo (que deve ser minimizada)
é o erro médio quadrático.



Modelo linear (hipótese)

$$h(x) = \hat{y} = b_0 + b_1 \cdot x$$

Função de Custo


$$fc(b_0, b_1) = MSE = \frac{\sum_{i=1}^N (\hat{y} - y_i)^2}{N}$$

Objetivo


$$\min_{b_0, b_1} (fc(b_0, b_1))$$

Função de custo


$$fc(b_0, b_1) = MSE = \frac{\sum_{i=1}^N \left(\overbrace{b_0 + b_1 \cdot x_i}^{\hat{y}} - y_i \right)^2}{N}$$



Gradiente Descendente



Derivada de uma função



$$\leftarrow y = f(x)$$

$$\leftarrow \text{inclinação} = \frac{dy}{dx} =$$

$$= f'(x_1) =$$

$$= \dot{y} = y'$$



A derivada de uma função $y = f(x)$ em um dado ponto x_1 é a inclinação da **reta tangente à curva** no ponto x_1 ,

isto é, é a **tangente do ângulo entre a reta tangente à curva no ponto x_1 e o eixo x**

Vetor Gradiente


- O **vetor gradiente** (ou apenas gradiente), é um vetor que aponta para a direção de maior variação da função em um determinado ponto
- É formado pelas derivadas parciais de cada variável da função

O campo gradiente $\langle 2x - 4, 2y + 2 \rangle$



da função $f = x^2 - 4x + y^2 + 2y$

Gradiente Descendente



Gradiente Descendente: algoritmo

Dada uma função de custo $fc(b_0, b_1)$

O objetivo é $\min_{b_0, b_1} (fc(b_0, b_1))$

1. inicie os parâmetros b_0, b_1 (por exemplo, $b_0 = 0, b_1 = 0$);
2. varie b_0, b_1 de modo a reduzir $fc(b_0, b_1)$
enquanto o valor de fc for menor que o anterior
3. quando o valor de fc não se reduzir mais,
chegou-se a um mínimo (local ou global)

Gradiente Descendente: algoritmo

Repita

$$temp_0 = b_0 - \alpha \frac{\partial}{\partial b_0} fc(b_0, b_1)$$

$$temp_1 = b_1 - \alpha \frac{\partial}{\partial b_1} fc(b_0, b_1)$$

$$b_0 = temp_0$$


$$b_1 = temp_1$$

até convergir

taxa de aprendizado




A taxa de aprendizado



$$b_1 = b_1 - \alpha \frac{\partial}{\partial b_1} f_c(b_1)$$


\uparrow
 ≥ 0




$$b_1 = b_1 - \alpha \frac{\partial}{\partial b_1} f_c(b_1)$$

\uparrow
 ≤ 0

A taxa de aprendizado



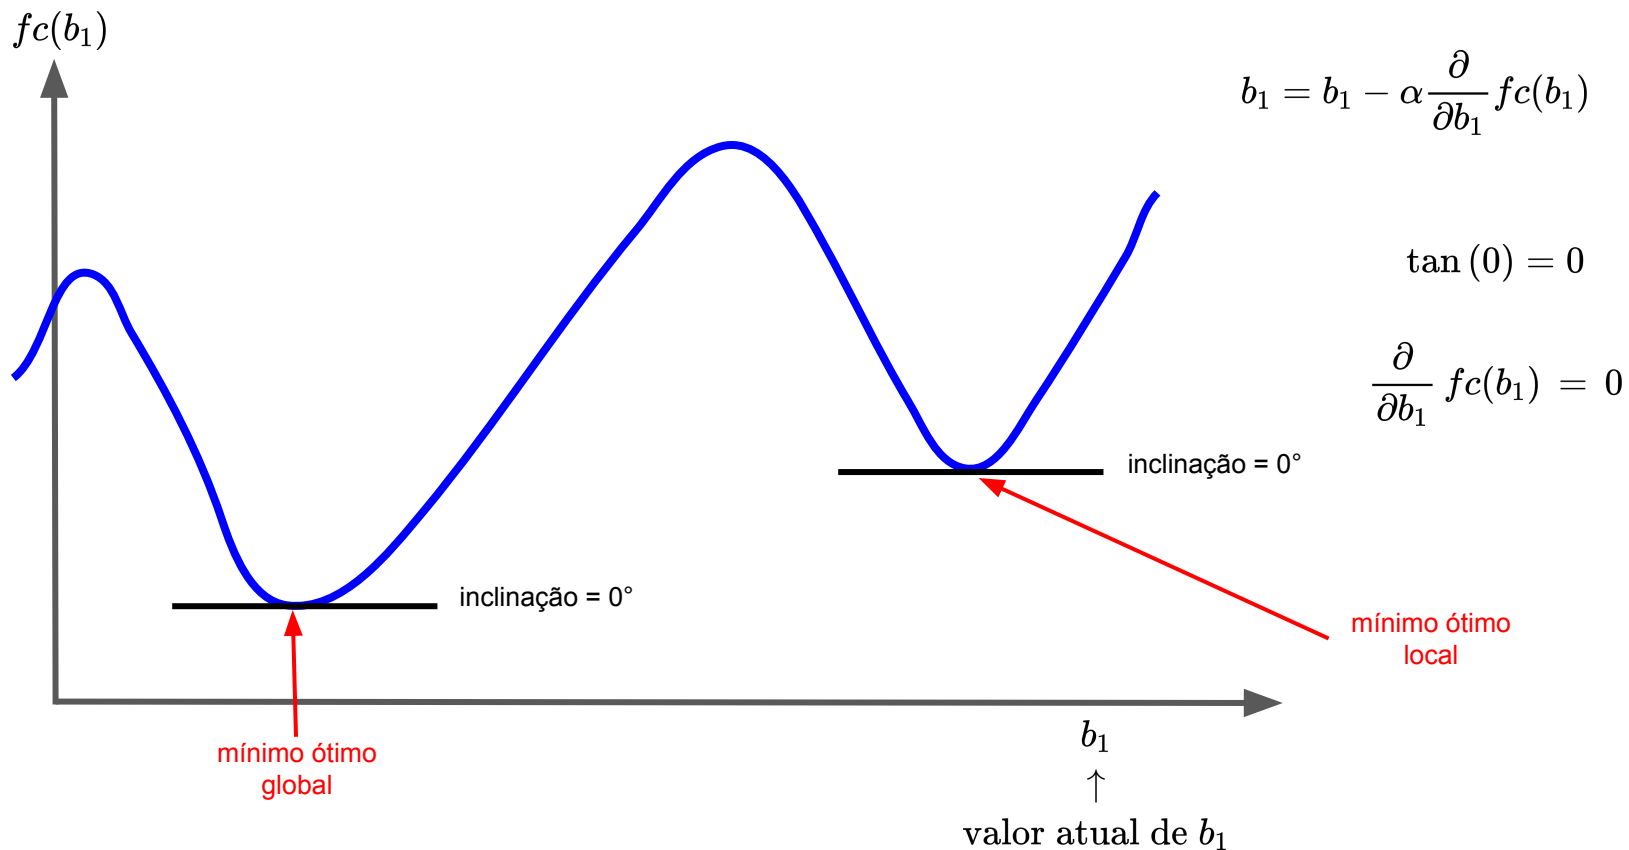
$$b_1 = b_1 - \alpha \frac{\partial}{\partial b_1} J(b_1)$$



Se α é muito pequeno, o gradiente descendente pode ser **lento**

Se α é muito grande, o gradiente descendente pode sempre **passar pelo mínimo** em ambos os sentidos. A convergência pode falhar

Mínimos locais e globais



Gradiente Descendente para Regressão Linear

Embora o algoritmo de gradiente descendente possa convergir para um mínimo local, isto não será problema para a regressão linear, uma vez que estamos utilizando uma função de custo que é uma **função convexa**

